Введение в искусственный интеллект. Современное компьютерное зрение

Лекция 3. Методы оптимизации нейронных сетей

Бабин Д.Н., Иванов И.Е., Петюшко А.А.

кафедра Математической Теории Интеллектуальных Систем

15 октября 2019

План лекции

1. Инициализация весов нейронной сети
2. Градиентный спуск
3. Модификации градиентного спуска для обучения нейронных сетей
4. Граф вычислений
5. Метод обратного распространения ошибки

Этапы подготовки модели к обучению

1. Выбор архитектуры
2. Выбор функции потерь
3. **Инициализация весов**
4. Решение оптимизационной задачи

Методы инициализации весов нейронной сети

- Инициализация нулями
- Инициализация единицами или другими константами
- Инициализация нормально распределенными значениями
- Инициализация равномерно распределенными значениями
- Инициализация значениями из усеченного нормального распределения
- Инициализация случайной ортогональной матрицей
- Инициализация единичной матрицей

Более продвинутые методы инициализации весов нейронной сети

- Lecun-инициализация [1] (n_i — количество входов (нейронов) i-го слоя)

$$W \sim U[-\sqrt{\frac{3}{n_i}}, \sqrt{\frac{3}{n_i}}], \; b \sim 0$$

- Xavier-инициализация [2]

$$W \sim U[-\frac{\sqrt{6}}{\sqrt{n_i + n_{i+1}}}, \frac{\sqrt{6}}{\sqrt{n_i + n_{i+1}}}], \; b \sim 0$$

[1] LeCun Y. A. et al. Efficient backprop. 1998.

[2] **Xavier** Glorot and Y. Bengio. Understanding the difficulty of training deep feedforward neural networks. 2010.

Более продвинутые методы инициализации весов нейронной сети

- Инициализация для ReLU сетей [3]

$$W \sim N(0, \sqrt{\frac{2}{n_i}}), \; b \sim 0$$

[3] K. He, X. Zhang, S. Ren, and J. Sun. Delving deep into rectifiers: Surpassing human-level performance on imagenet classification. 2015.

Этапы подготовки модели к обучению

1. Выбор архитектуры
2. Выбор функции потерь
3. Инициализация весов
4. **Решение оптимизационной задачи**

Методы оптимизации нейронной сети

Оптимизационная задача

$$L(x, \theta) = \sum_{(x_i, y_i) \in train} L(x_i, y_i, \theta) \to \min_{\theta}$$

Градиентный спуск

$$\omega[t+1] = \omega[t] - \alpha[t] \bigtriangledown (L, w[t])$$

Почему сложно обучать нейронную сеть

- Не всегда оптимизируемая функция дифференцируема
- Даже если она дифференцируемая, то иногда производная бывает тривиальной (для кусочно-постоянных функций)

Почему обучать нейронную сеть сложно

Почему сложно обучать нейронную сеть

- Не всегда оптимизируемая функция дифференцируема
- Даже если она дифференцируемая, то иногда производная бывает тривиальной (для кусочно-постоянных функций)
- В большинстве случаев оптимизируемая функция не является выпуклой и имеет множество локальных минимумов
- Даже если мы попали в глобальный минимум никто не обещает, что это хорошо, так как это может быть переобучением

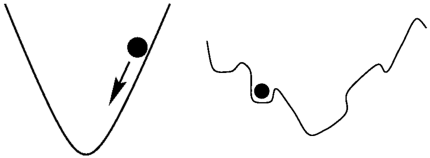

4

[4] https://www.willamette.edu/~gorr/classes/cs449/momrate.html

Методы оптимизации

- Градиентный спуск
- Стохастический градиентный спуск [5]
- Стохастический градиентный спуск с использованием мини-батча

[5] H. Robbins, and S. Monro. A Stochastic Approximation Method. 1951.

Достоинства и недостатки градиентного спуска

Достоинства

- Он работает
- Серьёзных альтернатив градиентному спуску нет

Недостатки

- Выбор шага градиентного спуска довольно сложная задача
- Один и тот же шаг применяется ко всем параметрам при обновлении весов
- Нет гарантий сходимости в общем случае

[6]

[6] Иллюстрация работы алгоритма при большом и маленьком шагах обучения

Моментум [8]

Momentum

$$v[t+1] = \mu v[t] - \alpha[t] \bigtriangledown (L, w[t])$$

$$\omega[t+1] = \omega[t] + v[t+1]$$

- Типичное значение $\mu = 0.9$
- Направление шага алгоритма зависит от всех предыдущих значений градиентов взятых с экспоненциально убывающими коэффициентами

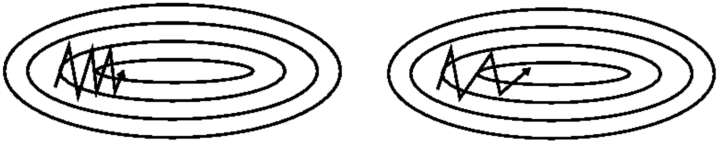

7

[7] https://www.willamette.edu/~gorr/classes/cs449/momrate.html

[8] Polyak, B.T. Some methods of speeding up the convergence of iteration methods. 1964.

Градиент Нестерова [9]

Nesterov accelerated gradient

$$v[t+1] = \mu v[t] - \alpha[t] \bigtriangledown (L, w[t] + \mu v[t])$$

$$\omega[t+1] = \omega[t] + v[t+1]$$

- Главная идея — вычисление градиента в более релевантной точке
- Перед вычислением градиента мы уже имеет хорошее приближение точки, где мы будем на следующем шаге.

[9] Nesterov, Y. A method of solving a convex programming problem with convergence rate O(1/sqr(k)). 1983.

Adaptive Gradient Algorithm [10]

Adagrad

$$g[t+1] = g[t] + \bigtriangledown(L, w[t]) \odot \bigtriangledown(L, w[t])$$

$$\omega[t+1] = \omega[t] - \frac{\alpha[t]}{\sqrt{g[t] + \varepsilon}} \odot \bigtriangledown(L, w[t])$$

- Главная идея — адаптирование шага градиента для различных направлений
- Веса, которые обновляются часто, имеют меньший шаг
- Главный недостаток, что $g[t]$ возрастает

[10] J. Duchi, E. Hazan, Y. Singer. Adaptive Subgradient Methods for Online Learning and Stochastic Optimization. 2011

Root Mean Square Propagation [11]

RMSprop

$$g[t+1] = \rho g[t] + (1-\rho) \bigtriangledown (L, w[t]) \odot \bigtriangledown (L, w[t])$$

$$\omega[t+1] = \omega[t] - \frac{\alpha[t]}{\sqrt{g[t] + \varepsilon}} \odot \bigtriangledown (L, w[t])$$

- Такая же основная идея, но немного другая реализация
- Типичное значение $\rho = 0.9$

[11] T. Tieleman and G. Hinton. Lecture 6.5-rmsprop: Divide the gradient by a running average of its recent magnitude. COURSERA: Neural Networks for Machine Learning. 2012.

Adadelta [12]

Adadelta

$$g[t+1] = \rho g[t] + (1-\rho) \bigtriangledown (L, w[t]) \odot \bigtriangledown (L, w[t])$$

$$\omega[t+1] = \omega[t] - \frac{\sqrt{d[t]+\varepsilon}}{\sqrt{g[t]+\varepsilon}} \odot \bigtriangledown (L, w[t])$$

$$d[t+1] = \rho d[t] + (1-\rho)(\omega[t+1] - \omega[t]) \odot (\omega[t+1] - \omega[t])$$

- Типичное значение $\rho = 0.9$

[12] Zeiler, Matthew D. ADADELTA: An adaptive learning rate method. 2012.

Adam [13]

Algorithm 1: *Adam*, our proposed algorithm for stochastic optimization. See section 2 for details, and for a slightly more efficient (but less clear) order of computation. g_t^2 indicates the elementwise square $g_t \odot g_t$. Good default settings for the tested machine learning problems are $\alpha = 0.001$, $\beta_1 = 0.9$, $\beta_2 = 0.999$ and $\epsilon = 10^{-8}$. All operations on vectors are element-wise. With β_1^t and β_2^t we denote β_1 and β_2 to the power t.

Require: α: Stepsize
Require: $\beta_1, \beta_2 \in [0, 1)$: Exponential decay rates for the moment estimates
Require: $f(\theta)$: Stochastic objective function with parameters θ
Require: θ_0: Initial parameter vector
  $m_0 \leftarrow 0$ (Initialize 1st moment vector)
  $v_0 \leftarrow 0$ (Initialize 2nd moment vector)
  $t \leftarrow 0$ (Initialize timestep)
  while θ_t not converged **do**
    $t \leftarrow t + 1$
    $g_t \leftarrow \nabla_\theta f_t(\theta_{t-1})$ (Get gradients w.r.t. stochastic objective at timestep t)
    $m_t \leftarrow \beta_1 \cdot m_{t-1} + (1 - \beta_1) \cdot g_t$ (Update biased first moment estimate)
    $v_t \leftarrow \beta_2 \cdot v_{t-1} + (1 - \beta_2) \cdot g_t^2$ (Update biased second raw moment estimate)
    $\widehat{m}_t \leftarrow m_t / (1 - \beta_1^t)$ (Compute bias-corrected first moment estimate)
    $\widehat{v}_t \leftarrow v_t / (1 - \beta_2^t)$ (Compute bias-corrected second raw moment estimate)
    $\theta_t \leftarrow \theta_{t-1} - \alpha \cdot \widehat{m}_t / (\sqrt{\widehat{v}_t} + \epsilon)$ (Update parameters)
  end while
  return θ_t (Resulting parameters)

[13] Diederik, Kingma; Ba, Jimmy. Adam: A method for stochastic optimization. 2014.

Adamax

Algorithm 2: *AdaMax*, a variant of Adam based on the infinity norm. See section 7.1 for details. Good default settings for the tested machine learning problems are $\alpha = 0.002$, $\beta_1 = 0.9$ and $\beta_2 = 0.999$. With β_1^t we denote β_1 to the power t. Here, $(\alpha/(1-\beta_1^t))$ is the learning rate with the bias-correction term for the first moment. All operations on vectors are element-wise.

Require: α: Stepsize
Require: $\beta_1, \beta_2 \in [0, 1)$: Exponential decay rates
Require: $f(\theta)$: Stochastic objective function with parameters θ
Require: θ_0: Initial parameter vector
  $m_0 \leftarrow 0$ (Initialize 1^{st} moment vector)
  $u_0 \leftarrow 0$ (Initialize the exponentially weighted infinity norm)
  $t \leftarrow 0$ (Initialize timestep)
  while θ_t not converged **do**
    $t \leftarrow t + 1$
    $g_t \leftarrow \nabla_\theta f_t(\theta_{t-1})$ (Get gradients w.r.t. stochastic objective at timestep t)
    $m_t \leftarrow \beta_1 \cdot m_{t-1} + (1 - \beta_1) \cdot g_t$ (Update biased first moment estimate)
    $u_t \leftarrow \max(\beta_2 \cdot u_{t-1}, |g_t|)$ (Update the exponentially weighted infinity norm)
    $\theta_t \leftarrow \theta_{t-1} - (\alpha/(1-\beta_1^t)) \cdot m_t/u_t$ (Update parameters)
  end while
  return θ_t (Resulting parameters)

Визуализация различных оптимизаторов

14

[14] http://ruder.io/optimizing-gradient-descent

Прочие подходы и эвристики

- Nadam [15]
- Cyclical Learning Rates for Training Neural Networks [16]
- Radam [17]
- Lookahead optimizer [18]
- ...
- Тут может быть ссылка на вашу работу

[15] Timothy Dozat. Incorporating Nesterov Momentum into Adam. 2015.
[16] L. Smith. Cyclical Learning Rates for Training Neural Networks. 2019.
[17] L. Liu, H. Jiang, P. He, W. Chen, X. Liu, J. Gao, J. Han. On the Variance of the Adaptive Learning Rate and Beyond. 2019.
[18] M. Zhang, J. Lucas, G. Hinton, J. Ba. Lookahead Optimizer: k steps forward, 1 step back. 2019.

Граф вычислений

- Нейронную сеть удобно представлять в виде ориентированного графа (очень часто ацикличного, но не всегда)
- В листьях такого дерева находятся входные данные
- В остальных вершинах находятся операции

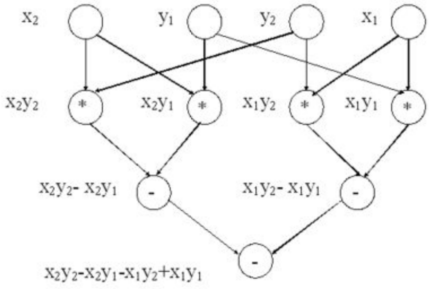

Производная сложной функции

$$z_1 = z_1(y_1, y_2)$$
$$z_2 = z_2(y_1, y_2)$$
$$y_1 = y_1(x_1, x_2)$$
$$y_2 = y_2(x_1, x_2)$$

Chain rule (производная сложной функции)

$$\frac{dz}{dx} = \begin{pmatrix} \frac{\partial z_1}{\partial x_1} & \frac{\partial z_1}{\partial x_2} \\ \frac{\partial z_2}{\partial x_1} & \frac{\partial z_2}{\partial x_2} \end{pmatrix} = \begin{pmatrix} \frac{\partial z_1}{\partial y_1}\frac{\partial y_1}{\partial x_1} + \frac{\partial z_1}{\partial y_2}\frac{\partial y_2}{\partial x_1} & \frac{\partial z_1}{\partial y_1}\frac{\partial y_1}{\partial x_2} + \frac{\partial z_1}{\partial y_2}\frac{\partial y_2}{\partial x_2} \\ \frac{\partial z_2}{\partial y_1}\frac{\partial y_1}{\partial x_1} + \frac{\partial z_2}{\partial y_2}\frac{\partial y_2}{\partial x_1} & \frac{\partial z_2}{\partial y_1}\frac{\partial y_1}{\partial x_2} + \frac{\partial z_2}{\partial y_2}\frac{\partial y_2}{\partial x_2} \end{pmatrix} = \begin{pmatrix} \frac{\partial z_1}{\partial y_1} & \frac{\partial z_1}{\partial y_2} \\ \frac{\partial z_2}{\partial y_1} & \frac{\partial z_2}{\partial y_2} \end{pmatrix} \begin{pmatrix} \frac{\partial y_1}{\partial x_1} & \frac{\partial y_1}{\partial x_2} \\ \frac{\partial y_2}{\partial x_1} & \frac{\partial y_2}{\partial x_2} \end{pmatrix}$$

$$\frac{dz}{dx} = \frac{dz}{dy}\frac{dy}{dx}$$

Метод обратного распространения ошибки [19]

Постановка задачи

Дано:

$$x_0 \xrightarrow{W_1} x_1 \xrightarrow{W_2} x_2 \to \ldots \xrightarrow{W_s} x_s, \text{ то есть } x_{i+1} = x_{i+1}(x_i, W_{i+1})$$

Найти:

$$\frac{dx_s}{dW_1}, \frac{dx_s}{dW_2}, \ldots, \frac{dx_s}{dW_s},$$

Схема вычисления

0. $\frac{dx_s}{dW_s}, \frac{dx_s}{dx_{s-1}}$
1. $\frac{dx_s}{dW_{s-1}} = \frac{dx_s}{dx_{s-1}} \frac{dx_{s-1}}{dW_{s-1}}, \frac{dx_s}{dx_{s-2}} = \frac{dx_s}{dx_{s-1}} \frac{dx_{s-1}}{dx_{s-2}}$
2. $\frac{dx_s}{dW_{s-2}} = \frac{dx_s}{dx_{s-2}} \frac{dx_{s-2}}{dW_{s-2}}, \frac{dx_s}{dx_{s-3}} = \frac{dx_s}{dx_{s-2}} \frac{dx_{s-2}}{dx_{s-3}}$

...

[19] D. Rumelhart, G. Hinton, R. Williams. Learning representations by back-propagating errors. 1986.

Метод обратного распространения ошибки

Схема вычисления

0. $\frac{dx_s}{dW_s}, \frac{dx_s}{dx_{s-1}}$

1. $\frac{dx_s}{dW_{s-1}} = \frac{dx_s}{dx_{s-1}} \frac{dx_{s-1}}{dW_{s-1}}, \frac{dx_s}{dx_{s-2}} = \frac{dx_s}{dx_{s-1}} \frac{dx_{s-1}}{dx_{s-2}}$

2. $\frac{dx_s}{dW_{s-2}} = \frac{dx_s}{dx_{s-2}} \frac{dx_{s-2}}{dW_{s-2}}, \frac{dx_s}{dx_{s-3}} = \frac{dx_s}{dx_{s-2}} \frac{dx_{s-2}}{dx_{s-3}}$

...

i. $\frac{dx_s}{dW_{s-i}} = \frac{dx_s}{dx_{s-i}} \frac{dx_{s-i}}{dW_{s-i}}, \frac{dx_s}{dx_{s-i-1}} = \frac{dx_s}{dx_{s-i}} \frac{dx_{s-i}}{dx_{s-i-1}}$

...

s-1. $\frac{dx_s}{dW_1} = \frac{dx_s}{dx_1} \frac{dx_1}{dW_1}$

Заключение

Главное правило: при обратном распространении градиента на каждом шаге необходимо считать производную по весам и по входу!

Метод обратного распространения ошибки

- Метод обратного распространения полностью соотвествует парадигме объектно-ориентированного программирования
- На каждом шаге необходимо вычислять градиент по весам и по входу
- Сложность алгоритма линейна относительно глубины цепочки зависимостей
- Метод позволяет вычислять производные довольно сложных функций, в графе которых нет циклов
- В случае, если в графе есть циклы, то существуют модификации алгоритма для разных специальных случаев

Заключение

- Важно инициализировать веса не нулями
- От параметров и выбора оптимизатора зависит скорость и качество обучения
- Исследования по методам оптимизации для нейронных сетей активно продолжаются
- На практике часто бывает, что SGD+momentum работает более стабильно
- Метод обратного распространения ошибки — эффективная схема вычисления градиента

Спасибо за внимание!